Harmonisation Sémantique des Données Agricoles

PHYTOLEX

Antoine Dalle

Table des matières

01 Introduction

02 Sources des données

03 Architecture technique

04 Pipeline de données

05 Enrichissement LLM

06 Dashboard Kibana

07 Résultats

08 Conclusion et perspectives

I. Introduction

1.1 Contexte

Le plan Ecophyto, initié par le ministère de l'Agriculture, vise à **réduire de 50 %** l'utilisation des produits phytosanitaires en France. Pour accompagner cette transition, le réseau **DEPHY** (Démonstration, Expérimentation et Production de références sur les systèmes économes en PHYtosanitaires) documente des **milliers d'expérimentations** agricoles à travers le territoire.

Parallèlement, la FAO maintient AGROVOC, un thésaurus multilingue de référence internationale contenant plus de 40 000 concepts agricoles normalisés, permettant l'interopérabilité des données agricoles à l'échelle mondiale.

Le problème : ces deux sources de données parlent le même langage métier mais utilisent des vocabulaires différents, rendant impossible leur croisement direct. Les connaissances terrain restent cloisonnées dans des fichiers Excel et des PDFs non structurés.

1.2 Objectif du projet PHYTOLEX

1. **Collecte** automatiquement les données DEPHY et AGROVOC via API REST et fichiers
2. **Harmonise** les schémas et normalise les formats en Parquet
3. **Aligne** sémantiquement les pratiques terrains français avec le vocabulaire scientifique international
4. **Enrichit** les alignements grâce à un LLM local (Gemma 3 12B) qui résout les synonymes non détectés par le matching exact
5. **Extrait** des connaissances structurées depuis les fiches PDF grâce au même LLM
6. **Expose** les résultats dans un dashboard Kibana interactif

1.3 Valeur métier

Utilisateurs	Bénéfice
Agriculteur	Trouver rapidement quelles pratiques fonctionne contre un bioagresseur donné
Conseiller agricole	Comparer les résultats d'expérimentations similaires par région et par culture
Chercheur	Croiser les données françaises avec les référentiels internationaux
Décideur public	Suivre l'évolution des pratiques et l'efficacité du plan Ecophyto

II. Sources de données

2.1 *Source n°1* — AGROVOC (API REST)

Food and Agriculture Organization of the United Nations

Fournisseur	Organisation des Nations Unies pour l'alimentation et l'agriculture (FAO)
Endpoint	API SPARQL publique
Protocole	Requêtes SPARQL via HTTP (REST API)
Contenu	40 000+ concepts agricoles normalisés avec labels multilingues (FR, EN), URIs uniques et relations hiérarchiques
Fréquence de mise à jour	Continue par la FAO
Format brut	JSON-LD
Volume extrait	~550 concepts liés au biocontrôle

2.2 *Source n°2* — DEPHY (Open Data)

Fournisseur	Réseau DEPHY / Ministère de l'Agriculture
Source	data.gouv.fr
Contenu	Fiches de pratiques agricoles documentant les leviers de réduction des phytosanitaires (cultures, doses, stades d'application, méthodes)
Format brut	Excel (.xlsx)
Volume	~460 fiches de systèmes de culture

2.3 *Source n°3*— Fiche Système (PDF)

Origine	URLs présentes dans le fichier Excel DEPHY
Format	Documents PDF de 4 à 10 pages
Contenu	• Contexte et objectifs de l'expérimentation • Stratégies de gestion par type de bioagresseur (schémas, tableaux) • Résultats chiffrés pluriannuels (rendements, IFT, taux de satisfaction) • Enseignements et recommandations des expérimentateurs • Coordonnées GPS des sites
Volume	~100–200 fiches PDF

2.4 *Source n°4* — Enrichissement LLM (dérivée)

Gemma 3

Origine	Résultat du mapping sémantique par Gemma 3 12B
Format brut	JSON (réponse LLM) → stocké dans raw/llm/synonyms/
Format formaté	Parquet + CSV seed DBT
Contenu	Correspondances sémantiques entre termes DEPHY non alignés et concepts AGROVOC
Volume	X mappings trouvés sur Y termes non alignés

III. Architecture technique

3.1 Vue d'ensemble

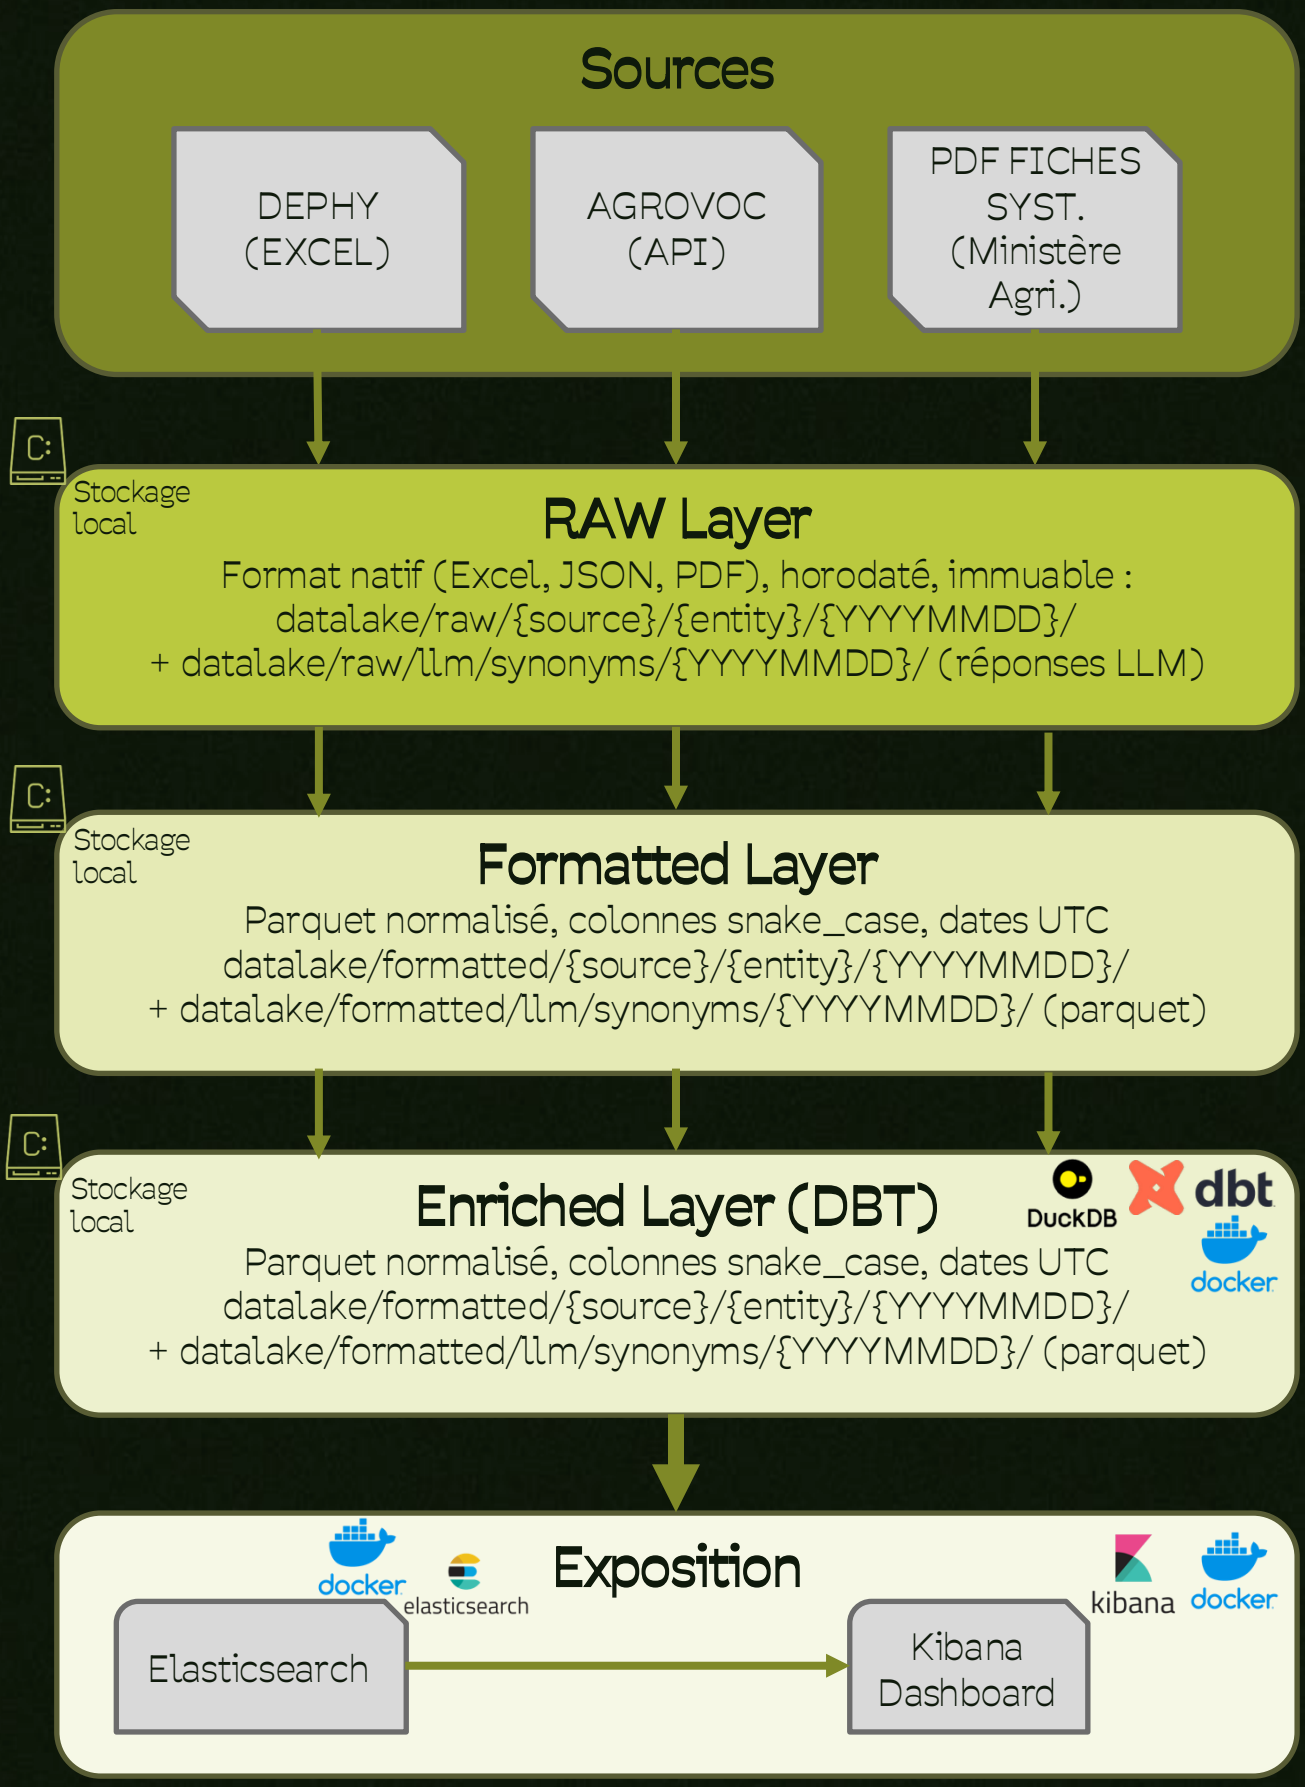

3.2 Organisation du DataLake

```
datalake/
│
├── raw/
│   ├── dephy/
│   │   ├── variableCards/
│   │   │   └── {YYYYMMDD}/
│   │   │       └── fichier-methodes-controle-biologique.xlsx
│   │   └── systemSheets/
│   │       └── {YYYYMMDD}/
│   │           ├── system_001.pdf
│   │           └── system_002.pdf
│   ├── agrovoc/
│   │   └── concepts/
│   │       └── {YYYYMMDD}/
│   │           └── agrovoc_biocontrol.json
│   └── llm/
│       └── synonyms/
│           └── {YYYYMMDD}/
│               └── llm_synonyms_raw.json
│
├── formatted/
│   ├── dephy/
│   │   ├── variableCards/
│   │   │   └── {YYYYMMDD}/
│   │   │       └── part-00001.parquet
│   │   └── systemSheets/
│   │       └── {YYYYMMDD}/
│   │           └── part-00001.parquet
│   ├── agrovoc/
│   │   └── concepts/
│   │       └── {YYYYMMDD}/
│   │           └── part-00001.parquet
│   └── llm/
│       └── synonyms/
│           └── {YYYYMMDD}/
│               └── llm_synonyms.parquet
│
└── enriched/
    └── biocontrol/
        └── alignments/
            └── {YYYYMMDD}/
                └── part-00001.parquet
```

Réponse brute LLM

normalisé, typé

mart final

IV. Pipeline de données

4.1 *Architecture des DAGs Airflow*

DAG 1: main_pipeline (pipeline principal)

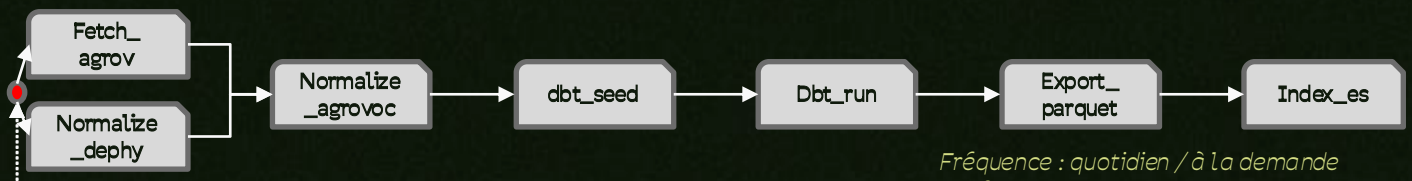

Fréquence : quotidien / à la demande
Durée : ~30 secondes

Ce DAG ne sollicite jamais le LLM. Il lit le seed CSV llm_synonyms.csv existant via DBT pour enrichir les alignements automatiquement (évite l'utilization des GPU noncontrolées

DAG 2: gaia_llm_synonyms (enrichissement sémantique)

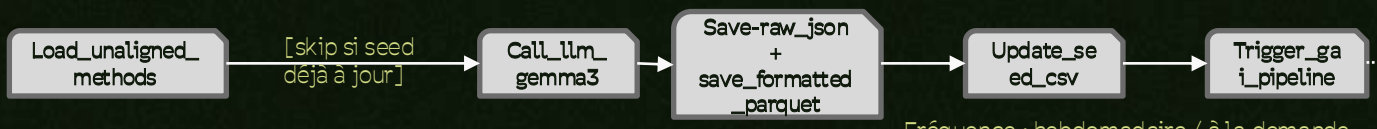

Fréquence : hebdomadaire / à la demande
Durée : ~2 minutes (dépend du GPU)

Logique incrémentale : à chaque run, le script ne soumet au LLM que les méthodes non encore présentes dans le seed CSV. Les résultats s'accumulent d'un run à l'autre :

- Run 1 : 82 méthodes non alignées → LLM trouve 58 mappings → 24 restent
- Run 2 : reprend les 24 restantes → LLM en trouve peut-être 10 de plus
- Run N : convergence progressive vers le maximum atteignable

DAG 3: gaia_llm_pdf_extract (extraction PDF)

Fréquence : manuellement / à la demande
Durée : ~5 minutes par PDF (~ 150 pdf)

Ce DAG sollicite un OCR et un LLM, avec une extraction de texte brute pour permettre au LLM de se concentrer uniquement sur la comprehension et structuration de la donnée

V. Dashboard & Visualisations

5.1 *Visualisations*

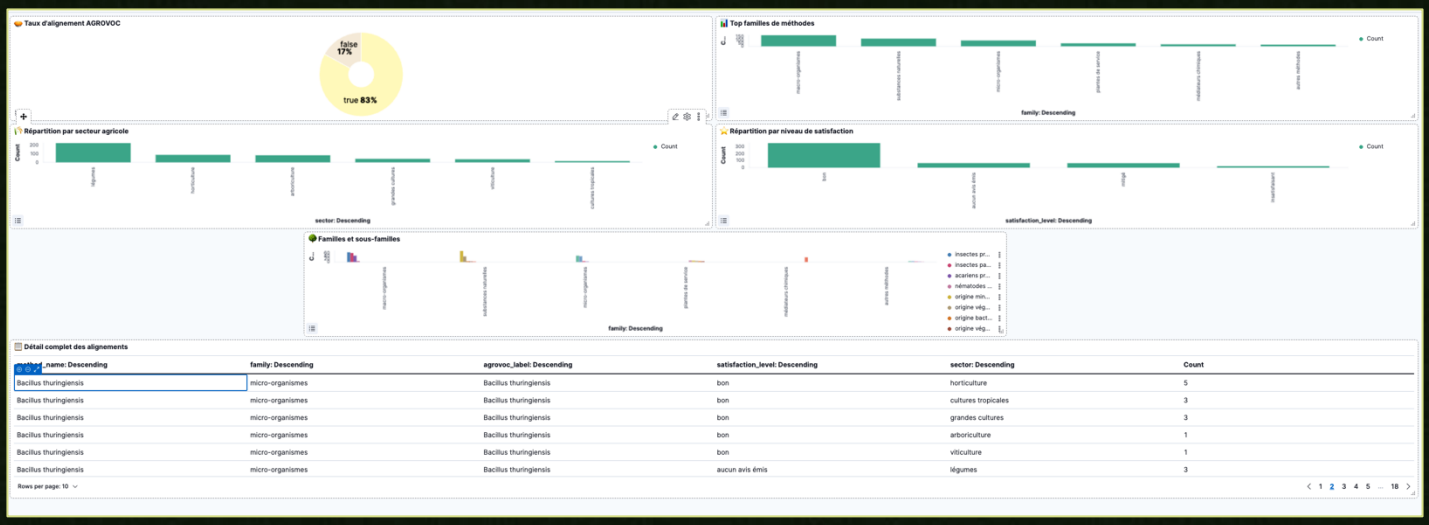

Figure 1: Visualisation Kibana

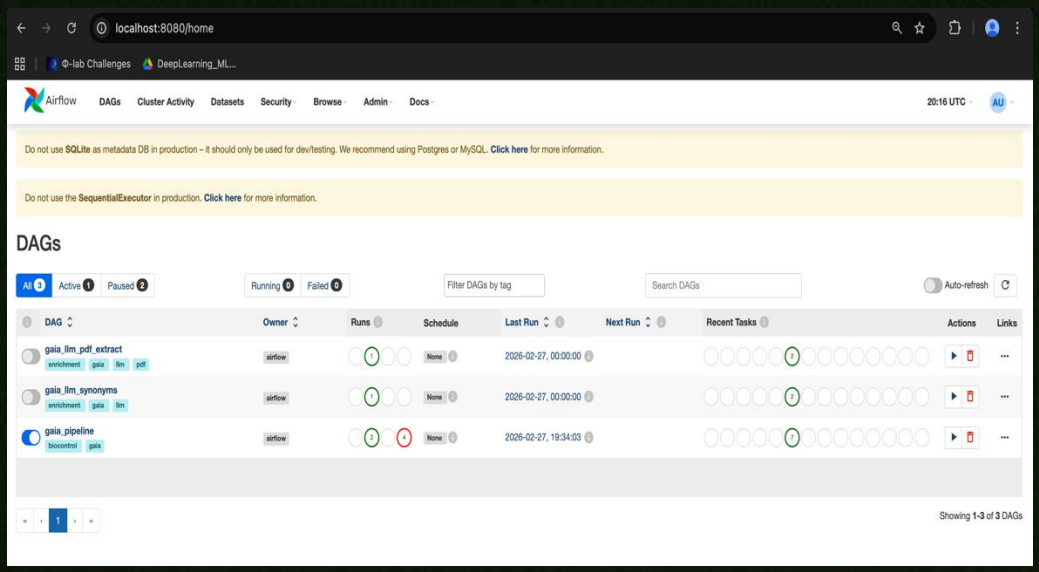

Figure 2: Visualisation des différents DAG (AirFlow)

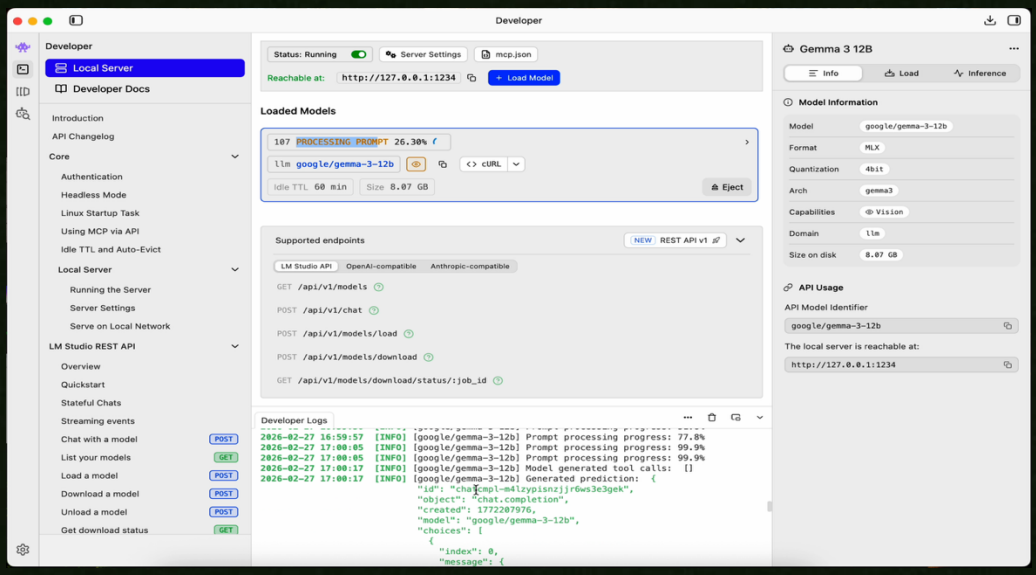

Figure 3: Visualisation du monitoring du LLM pendant l'inférence

5.2 Démonstration - Airflow

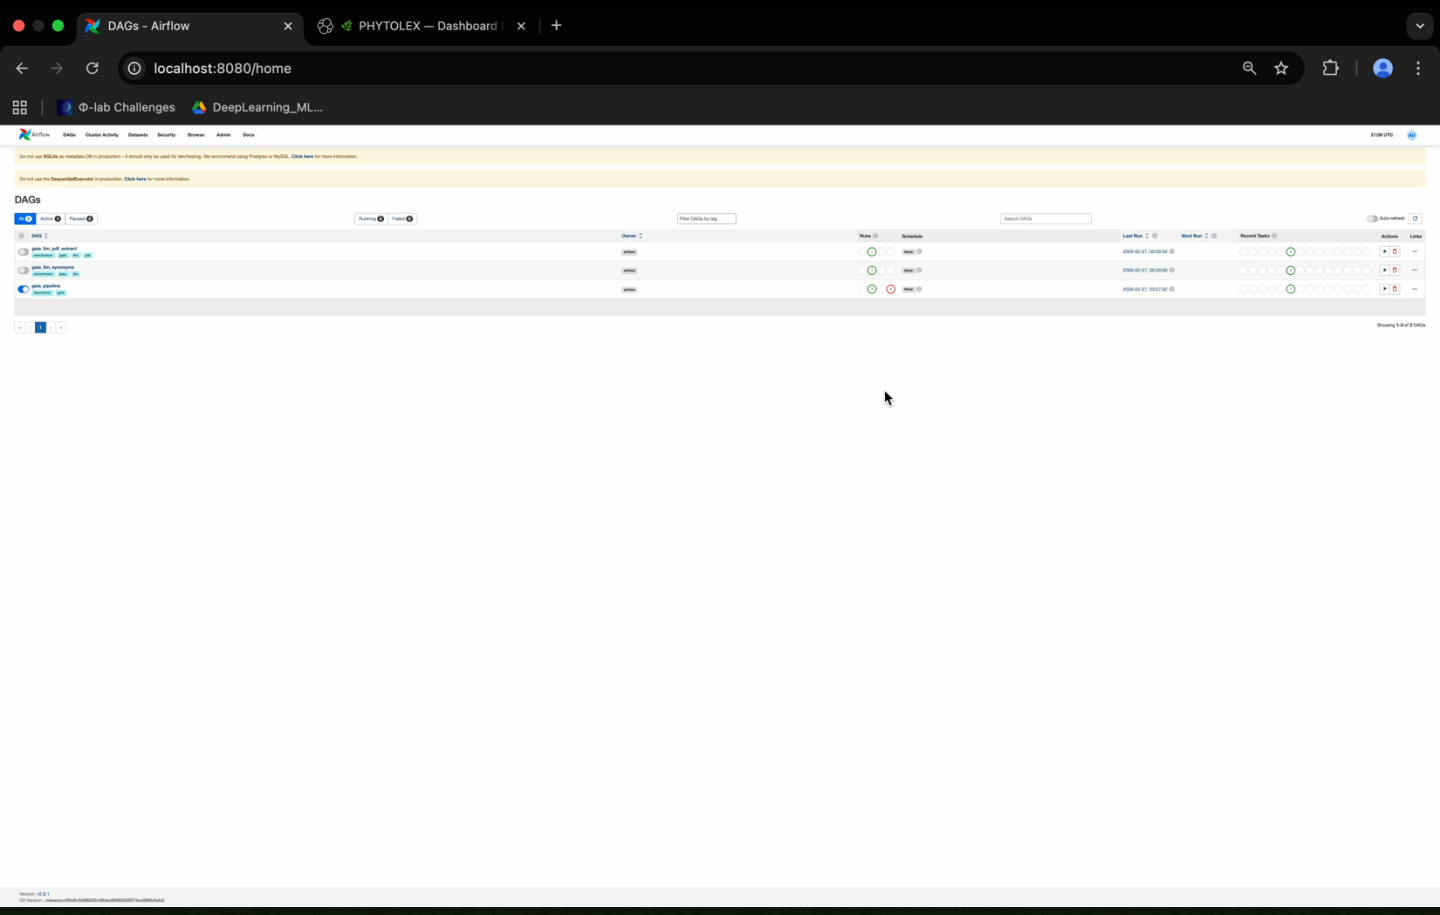

5.3 Démonstration – Extraction de PDF

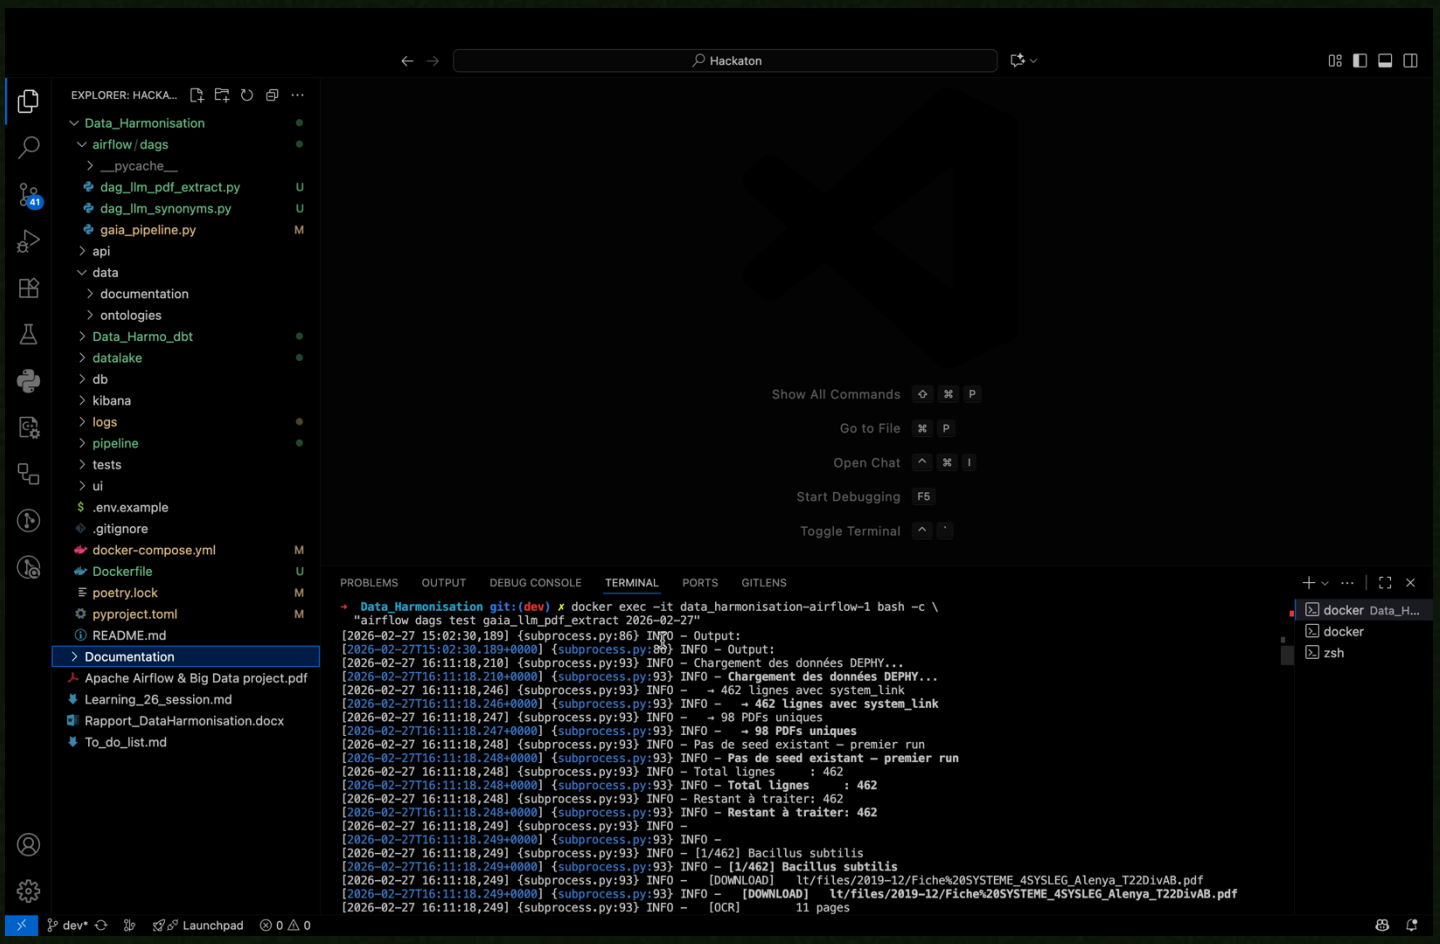

VI. Conclusion & perspectives

7.1 Ce qui a été accompli

Les principaux accomplissements de PHYTOLEX sont les suivants:

- Architecture Data Lake **4 couches propre et reproductible**, avec **chemins dynamiques**
- **3 DAGs Airflow découplés** : pipeline **rapide** (quotidien), enrichissement **LLM** (hebdomadaire), extraction **PDF** (à la demande)
- Enrichissement **sémantique** par **LLM incrémental** : taux d'alignement passé de **15 %** à **70** % grâce à Gemma 3 12B
- **Intégration** propre **LLM** ↔ **DBT** via un **seed CSV** cumulatif, sans **couplage entre le LLM** et le pipeline principal
- Extraction **intelligente** de connaissances **depuis des PDFs non structurés**
- **Dashboard Kibana** pour l'exploration interactive des **500 alignements enrichis**

7.2 Décisions architecturales et perspectives d'évolution

Décision prise	Justification	Evolution future
LLM en amont de DBT (pas dans DBT)	Pipeline principal **rapide** et **déterministe**	**Validation humaine** des mappings LLM
Seed CSV comme interface LLM → DBT	Simple, **versionnable**, **auditable**	**Remplacer par embeddings** vectoriels pour matching sémantique avancé
Logique incrémentale du LLM	**Chaque run** ne traite que les méthodes restantes	**Ingestion temps réel** (Kafka) pour nouvelles publications DEPHY
`get_latest_parquet()` partout	**Élimine les dates hardcodées**, pipeline robuste	**Déploiement** cloud pour accessibilité en **ligne**
API REST PHYTOLEX pour **intégration** dans des outils tiers	**Fonctionne** en **Docker** et en local	**API REST PHYTOLEX** pour intégration dans des **outils tiers**
Dashboard Kibana (500 alignements)	**Exploration interactive** des résultats enrichis	Corrélation avec données **météo historiques**

Course: DATA 705 – Data Lake – Février 2026 – Télécom Paris

Harmonisation Sémantique des Données Agricoles

[redacted]

GitHub Repo

Antoine Dalle

PHYTOLEX